

**Universidade Federal de Goiás**  
**Instituto de Informática**  
**Prof. Ronaldo Martins da Costa**






## “Consumindo” Modelos de IA

### ● KNN – *K nearest neighbors* (K Vizinhos mais Próximos)

Supondo que cada característica de seus dados (altura, peso, salário, nota obtida, valor, etc.) seja uma coordenada em um hiperplano

Através de métricas de calculo de distância é possível calcular a distância entre os diversos vetores de características (pontos)

$$D = \sqrt{\left( x_1 - x_2 \right)^2 + \left( y_1 - y_2 \right)^2 + \dots + \left( z_1 - z_2 \right)^2}$$







## “Consumindo” Modelos de IA

### ● KNN – *K nearest neighbors* (K Vizinhos mais Próximos)


Sendo assim, é possível calcular a distância entre todos os vetores de características e determinar quais os mais próximos. A acurácia é dada pela equação:

$$AC = \frac{\text{Classificação Correta}}{N^{\circ} \text{ Amostras}}$$





## “Consumindo” Modelos de IA

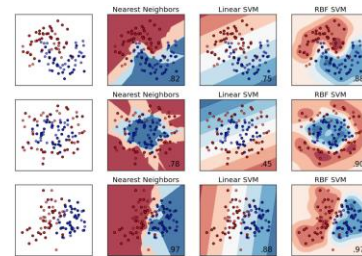


- Os modelos/classificadores podem ser:
  - Discretos  
Atribui cada elemento para uma classe
  - Contínuos  
Atribui uma probabilidade de um determinado elemento pertencer a uma classe, utilizando um limiar de separação entre as classes
- Assim, é necessário que possamos determinar o quanto preciso um modelo/classificador retorna resultados



## “Consumindo” Modelos de IA

- ☉ Toda classificação atribuirá classes aos elementos mas também está sujeita a erros por diversas razões (qualidade dos dados, falha na técnica de pré-processamento, erros na “limpeza” dos dados, etc.)





## “Consumindo” Modelos de IA

Resultado Ótimo

### CÃES



### GATOS





## “Consumindo” Modelos de IA


- ☉ Vários fatores podem induzir o classificador ao erro





## “Consumindo” Modelos de IA

- A sensibilidade do classificador pode ser verificada através da tabela a seguir, muito utilizada em exames clínicos, em aplicações da saúde, mas pode ser aplicada a muitos outros tipos de problemas



		Classe Real	
		+	-
Classe Predita	+	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	-	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Matriz de Confusão para 2 classes





## “Consumindo” Modelos de IA

### CÃES



		Classe Real	
		Cão (+)	Gato (-)
Classe Predita	Cão (+)	4 (VP)	2 (FP)
	Gato (-)	3 (FN)	5 (VN)

### GATOS

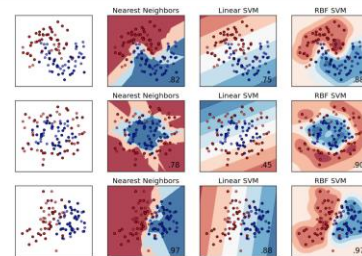




## “Consumindo” Modelos de IA

Baseado nos resultados da tabela, algumas informações importantes podem ser obtidas como:


- Sensibilidade
- Especificidade



		Classe Real		Total
		Cão (+)	Gato (-)	
Classe Predita	Cão (+)	4 (VP)	2 (FP)	6 (TP)
	Gato (-)	3 (FN)	5 (VN)	8 (TN)
	Total	7	7	14



## “Consumindo” Modelos de IA



### ☉ Sensibilidade – Equivalente a Taxa de Verdadeiros Positivos (*True Positive Rate* – TPR)

- ☉ A sensibilidade de um método reflete o quanto este é eficaz em identificar corretamente, dentre todos os indivíduos avaliados, aqueles que realmente apresentam a característica de interesse

$$S = \frac{VP}{VP + FN}$$


$$S = \frac{4}{4 + 3}$$

$$S = 0,57 \quad \text{ou} \quad 57\%$$

		Classe Real		Total
		Cão (+)	Gato (-)	
Classe Predita	Cão (+)	4 (VP)	2 (FP)	6 (TP)
	Gato (-)	3 (FN)	5 (VN)	8 (TN)
	Total	7	7	14



## “Consumindo” Modelos de IA



### ● Especificidade – Equivalente a Taxa de Falso Positivos (*False Positive Rate* – FPR)

- Reflete o quanto ele é eficaz em identificar corretamente os indivíduos que não apresentam a condição de interesse

$$S = \frac{VN}{VN + FP}$$

$$S = \frac{5}{5 + 2}$$


$$S = 0,71 \text{ ou } 71\%$$

		Classe Real		Total
		Cão (+)	Gato (-)	
Classe Predita	Cão (+)	4 (VP)	2 (FP)	6 (TP)
	Gato (-)	3 (FN)	5 (VN)	8 (TN)
	Total	7	7	14



## “Consumindo” Modelos de IA


- Para que uma técnica seja estatisticamente robusta, é necessário que alguns aspectos sejam observados
- Tomando como exemplo uma pesquisa eleitoral, para que as "previsões" se aproxime o máximo do resultado real é necessário que os dados representem uma parte significativa da população, possuindo dados de todas as idades, gêneros, classes, regiões geográficas, etc.
- Mas como fazer com que um modelo apresente resultados que representam TODOS os dados de um conjunto ?





## “Consumindo” Modelos de IA


- O objetivo é encontrar um modelo que produza previsões para dados futuros/desconhecidos com erro relativo mínimo
- Dessa forma, “alimentamos” o modelo com uma parte dos dados, a chamada amostra de **treino** (70% a 80%)
- No entanto, queremos saber sobre o futuro. Para isso utilizamos o modelo para produzir previsões para o restante dos dados, a chamada amostra de **teste** (20% a 30%)





## “Consumindo” Modelos de IA

- A separação dos dados em Treino e Teste, em geral não é suficiente. Uma solução mais adequada é a separação em 3(três) subconjuntos:
- Treino (70% a 80%)
  - Utilizado para treinar o modelo, ou seja, para ajustar os parâmetros internos do modelo (como pesos em redes neurais, coeficientes, etc.)
- Validação (10% a 15%)
  - Durante o treinamento, o desempenho é monitorado no conjunto de validação para ajustar os hiperparâmetros e prevenir o *overfitting*
- Teste (10% a 15%)
  - Após o ajuste e treinamento, o modelo é testado com o conjunto de teste para avaliar sua capacidade de generalizar a dados que nunca foram vistos antes






## “Consumindo” Modelos de IA

### Overfitting

- Problema que ocorre quando o modelo responde muito bem nos dados de treinamento, mas terá um desempenho ruim em novos dados ou no conjunto de teste, porque o modelo não aprendeu os padrões gerais dos dados, mas sim os ruídos ou as flutuações aleatórias presentes nos dados de treinamento








## “Consumindo” Modelos de IA

### Cross Validation

### ● Validação Cruzada

É uma técnica para avaliar como o resultado de uma análise estatística generalizará para um conjunto independente de dados.

É usado para estimar o quão preciso um classificador será na prática





# “Consumindo” Modelos de IA

## Cross Validation

### Gerando um classificador




Conjunto de Treino

Classificador

Conjunto de Teste

		Classe Real	
		+	-
Classe Predita	+	(VP)	(FP)
	-	(FN)	(VN)






# “Consumindo” Modelos de IA

## Validação Cruzada

## Cross Validation



K Fold 1

K Fold 2

K Fold 3

K Fold 1

K Fold 2

K Fold 3

K Fold 2  
+  
K Fold 3

K Fold 1  
+  
K Fold 3

K Fold 1  
+  
K Fold 2

Classificador

Classificador

Classificador

K = 10

		Classe Real	
		+	-
Classe Predita	+	(VP)	(FP)
	-	(FN)	(VN)

		Classe Real	
		+	-
Classe Predita	+	(VP)	(FP)
	-	(FN)	(VN)

		Classe Real	
		+	-
Classe Predita	+	(VP)	(FP)
	-	(FN)	(VN)

Acurácia = Média



## “Consumindo” Modelos de IA

### Matriz de confusão para N classes

		Classe Real			
		Cachorro	Coelho	Gato	Lobo
Classe Predit	Cachorro	80	0	2	10
	Coelho	10	50	8	5
	Gato	0	0	70	5
	Lobo	10	0	0	100



100 Cães



50 Coelhoos



80 Gatos



120 Lobos

Confusion Matrix

	1	2	3	4	
1	90 (90%)	2 (2%)	1 (1%)	8 (8%)	101 (91%)
2	1 (1%)	50 (50%)	1 (1%)	10 (10%)	62 (53%)
3	0 (0%)	0 (0%)	70 (70%)	5 (5%)	75 (65%)
4	10 (10%)	0 (0%)	0 (0%)	100 (100%)	110 (90%)
	101 (91%)	53 (47%)	75 (65%)	110 (90%)	

Total Classificado Corretamente  
dividido por  
Total de Elementos


$$300 / 350 = 0,857 \text{ ou } 85,7$$



## “Consumindo” Modelos de IA

### ● Curva ROC

- “*Receiver Operating Characteristic*”, que pode ser traduzido livremente como “eficiência do operador de recepção de sinais”
- A curva ROC mostra a relação entre a taxa de verdadeiros positivos (TPR) e a taxa de falsos positivos (FPR) para diferentes limiares de decisão
- Eixo X: Taxa de Falso Positivo (*False Positive Rate* – FPR)
- Eixo Y: Taxa de Verdadeiro Positivo (*True Positive Rate* – TPR)
- Ao traçar a curva, o objetivo é observar como a TPR se comporta em função da FPR à medida que o limiar de decisão do modelo é ajustado. O ideal é que o modelo tenha uma TPR alta e uma FPR baixa, o que coloca a curva o mais próximo possível do canto superior esquerdo do gráfico
- O método foi originalmente desenvolvido para avaliar a capacidade de operadores de radar em decidir se uma mancha na tela representava um alvo inimigo ou um aliado

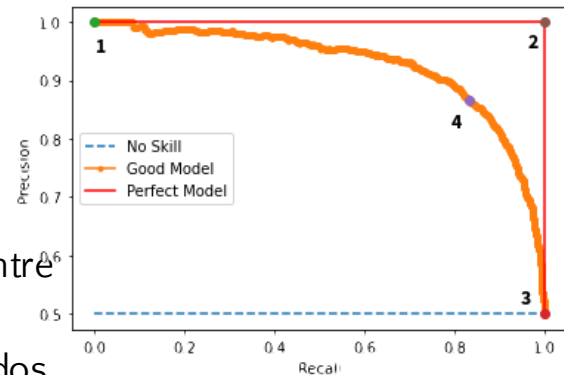




## “Consumindo” Modelos de IA

### Curva *Precision-Recall* (PR)

- Precisão (*Precision*): É a proporção de verdadeiros positivos entre todos os positivos preditos
- Revocação (*Recall*): É a capacidade do modelo de capturar todos os exemplos positivos reais
- Eixo X: *Recall* — A proporção de instâncias positivas corretamente identificadas
- Eixo Y: *Precision* — A proporção de instâncias classificadas como positivas que são realmente positivas
- Assim como a área sob a curva ROC, a área sob a curva *Precision-Recall* é uma métrica de desempenho do modelo. Quanto maior a AUC-PR, melhor o desempenho do modelo, pois ele tem boa precisão e boa revocação em um grande número de diferentes limiares





## “Consumindo” Modelos de IA

### CÃES



Considerando que o resultado foi:  
4 cães e 1 gato

$$Recall = \frac{ClassificaçõesCorretas}{QuantidadeTotalClasse}$$

$$Precision = \frac{ClassificaçõesCorretas}{QuantidadeClassificada}$$





## “Consumindo” Modelos de IA

### CÃES



Considerando que o resultado foi:  
4 cães e 1 gato

$$Recall = \frac{4}{6} = 0,66 \text{ ou } 66\%$$

$$Precision = \frac{4}{5} = 0,80 \text{ ou } 80\%$$







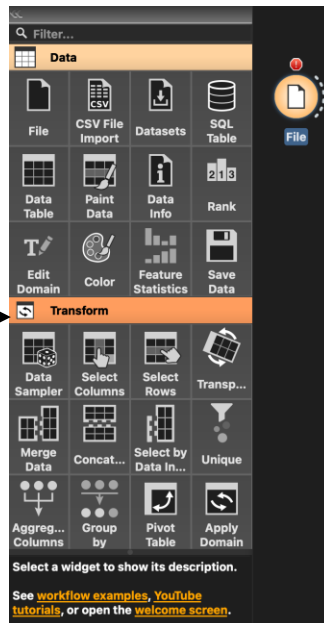
## “Consumindo” Modelos de IA

### Realizando um treinamento e validação com o Software Orange

- Crie um novo projeto, selecione o ícone FILE e associe ao conjunto de dados que você possui, uma das colunas deve ser o TARGET para classificação



New



Source

File: Downloads/framework-aula-5-ml.xlsx

URL:

File Type

Automatically detect type

Info

42 instances  
33 features (no missing values)  
Data has no target variable.  
0 meta attributes

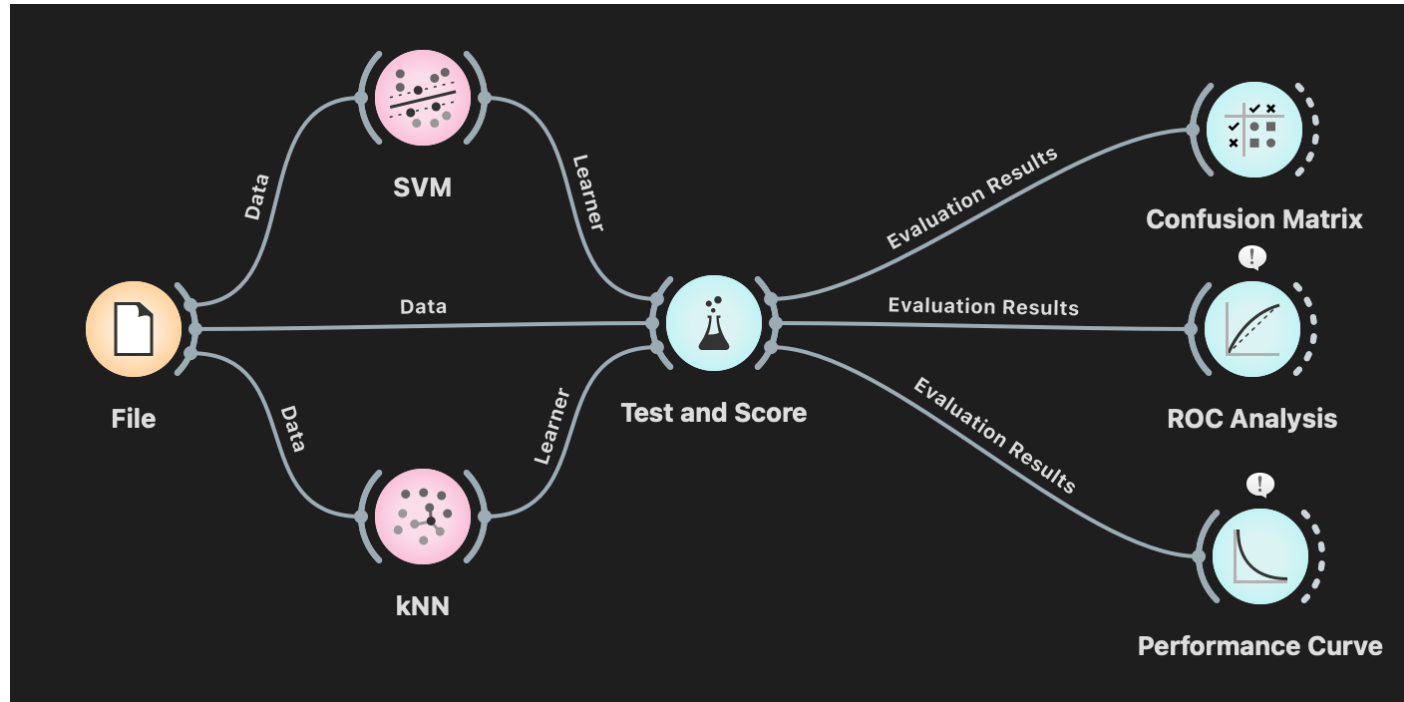
Columns (Double click to edit)

	Name	Type	Role	Values
1	Grupo	C categori...	target	Controle, Experimental
2	mdw	N numeric	feature	
3	latw	N numeric	feature	
4	tmcw	N numeric	feature	
5	racw	N numeric	feature	
6	araw	N numeric	feature	
7	mcw	N numeric	feature	
8	psdw	N numeric	feature	
9	6sw	N numeric	feature	
10	mdr	N numeric	feature	
11	latr	N numeric	feature	



## “Consumindo” Modelos de IA

- Realizando um treinamento e validação com o Software Orange
- Selecione os modelos e ferramentas de avaliação desejados





## “Consumindo” Modelos de IA



- Criando um model no DB para receber os valores que serão importados na APP exemplo02

```
from django.db import models

class dados(models.Model):
    grupo = models.CharField(max_length=50, null=True, blank=True,
        verbose_name='Grupo')
    mdw = models.FloatField(null=True, blank=True, verbose_name='mdw')
    latw = models.FloatField(null=True, blank=True, verbose_name='latw')
    tmcw = models.FloatField(null=True, blank=True, verbose_name='tmcw')
    racw = models.FloatField(null=True, blank=True, verbose_name='racw')
    araw = models.FloatField(null=True, blank=True, verbose_name='araw')
    mcw = models.FloatField(null=True, blank=True, verbose_name='mcw')
    psdsw = models.FloatField(null=True, blank=True, verbose_name='psdsw')
    s6w = models.FloatField(null=True, blank=True, verbose_name='s6w')
    mdr = models.FloatField(null=True, blank=True, verbose_name='mdr')
    latr = models.FloatField(null=True, blank=True, verbose_name='latr')
    tmcr = models.FloatField(null=True, blank=True, verbose_name='tmcr')
    racr = models.FloatField(null=True, blank=True, verbose_name='racr')
```



## “Consumindo” Modelos de IA



- Criando um model no DB para receber os valores que serão importados na APP exemplo02

```
arar = models.FloatField(null=True, blank=True, verbose_name='arar')
mcr = models.FloatField(null=True, blank=True, verbose_name='mcr')
psdsr = models.FloatField(null=True, blank=True, verbose_name='psdsr')
s6r = models.FloatField(null=True, blank=True, verbose_name='s6r')
mdg = models.FloatField(null=True, blank=True, verbose_name='mdg')
latg = models.FloatField(null=True, blank=True, verbose_name='latg')
tmcg = models.FloatField(null=True, blank=True, verbose_name='tmcg')
racg = models.FloatField(null=True, blank=True, verbose_name='racg')
arag = models.FloatField(null=True, blank=True, verbose_name='arag')
mcg = models.FloatField(null=True, blank=True, verbose_name='mcg')
psdsg = models.FloatField(null=True, blank=True, verbose_name='psdsg')
s6g = models.FloatField(null=True, blank=True, verbose_name='s6g')
mdwb = models.FloatField(null=True, blank=True, verbose_name='mdwb')
latb = models.FloatField(null=True, blank=True, verbose_name='latb')
tmcb = models.FloatField(null=True, blank=True, verbose_name='tmcb')
racb = models.FloatField(null=True, blank=True, verbose_name='racb')
arab = models.FloatField(null=True, blank=True, verbose_name='arab')
```



## “Consumindo” Modelos de IA



- Criando um model no DB para receber os valores que serão importados na APP exemplo02

```
mcb = models.FloatField(null=True, blank=True, verbose_name='mcb')
psdsb = models.FloatField(null=True, blank=True, verbose_name='psdsb')
s6b = models.FloatField(null=True, blank=True, verbose_name='s6b')

def __str__(self):
    return self.grupo

class Meta:
    ordering = ['grupo']
```



## “Consumindo” Modelos de IA



### ● Atualizando o modelo no DB

```
python manage.py makemigrations exemplo02
```

```
python manage.py migrate
```



## “Consumindo” Modelos de IA

- Se os ajustes no model foram realizados corretamente, você verá uma tela como esta



```
• (BigData-env) ronaldocosta@Ronaldos-MacBook-Pro bdpratico % python manage.py makemigrations exemplo02
Migrations for 'exemplo02':
  exemplo02/migrations/0001_initial.py
    - Create model dados
• (BigData-env) ronaldocosta@Ronaldos-MacBook-Pro bdpratico % python manage.py migrate
Operations to perform:
  Apply all migrations: admin, auth, contenttypes, exemplo01, exemplo02, sessions
Running migrations:
  Applying exemplo02.0001_initial... OK
```





## “Consumindo” Modelos de IA

- Na APP Exemplo02, vamos criar as novas rotas

```
from django.contrib import admin
from django.urls import path
from . import views

urlpatterns = [
    path('', views.index, name='index'),
    path('ia_import', views.ia_import, name='ia_import'),
    path('ia_import_save', views.ia_import_save, name='ia_import_save'),
    path('ia_import_list', views.ia_import_list, name='ia_import_list'),
]
```







## “Consumindo” Modelos de IA



### ● Criando as views necessárias na App exemplo02

```
def ia_import(request):  
    return render(request, 'ia_import.html')
```



## “Consumindo” Modelos de IA



### ● Criando as views necessárias na App exemplo02

```
def ia_import_save(request):
    from .models import dados
    import os
    from django.core.files.storage import FileSystemStorage
    if request.method == 'POST' and request.FILES['arq_upload']:
        fss = FileSystemStorage()
        upload = request.FILES['arq_upload']
        file1 = fss.save(upload.name, upload)
        file_url = fss.url(file1)
        from .models import dados
        dados.objects.all().delete()
        i = 0
        file2 = open(file1, 'r')
        for row in file2:
            if (i > 0):
                row2 = row.replace(',', ' ')
                row3 = row2.split(';')
                dados.objects.create(
                    grupo = row3[0], mdw = float(row3[1]), latw = float(row3[2]),
                    tmcw = float(row3[3]), racw = float(row3[4]), araw = float(row3[5]),
                    mcw = float(row3[6]), psdsw = float(row3[7]), s6w = float(row3[8]),
                    mdr = float(row3[9]), latr = float(row3[10]), tmcr = float(row3[11]),
                    racr = float(row3[12]), arar = float(row3[13]), mcr = float(row3[14]),
```



## “Consumindo” Modelos de IA



### ● Criando as views necessárias na App exemplo02

```
        racr = float(row3[12]), arar = float(row3[13]), mcr = float(row3[14]),
        psdsr = float(row3[15]), s6r = float(row3[16]), mdg = float(row3[17]),
        latg = float(row3[18]), tmcg = float(row3[19]), racg = float(row3[20]),
        arag = float(row3[21]), mcg = float(row3[22]), psdsg = float(row3[23]),
        s6g = float(row3[24]), mdwb = float(row3[25]), latb = float(row3[26]),
        tmcb = float(row3[27]), racb = float(row3[28]), arab = float(row3[29]),
        mcb = float(row3[30]), psdsb = float(row3[31]), s6b = float(row3[32]))

    i = i + 1
    file2.close()
    os.remove(file_url.replace("/", ""))
from django.shortcuts import redirect
return redirect('ia_import_list')
```



## “Consumindo” Modelos de IA



### ● Criando as views necessárias na App exemplo02

```
def ia_import_list(request):  
    from .models import dados  
    data = {}  
    data['dados'] = dados.objects.all()  
    return render(request, 'ia_import_list.html', data)
```



## “Consumindo” Modelos de IA



### ● Criando os templates necessárias na App exemplo02

```
<!DOCTYPE html>
<html lang="en">
  <head>
    <meta charset="UTF-8" />
    <title>IA Import.html</title>
  </head>

  <body>
    <h1>Upload / Import Arquivo!</h1>
    <p>bdpratico\exemplo02\templates\ia_import.html</p>
    <form method="post" enctype="multipart/form-data" action="{% url 'ia_import_save' %}">
      {% csrf_token %}
      <input type="file" name="arq_upload" />
      <button type="submit">Upload</button>
    </form>
  </body>
</html>
```



## “Consumindo” Modelos de IA



### ● Criando os templates necessárias na App exemplo02

```
{% load static %}
{% load bootstrap5 %}
{% bootstrap_css %}
{% bootstrap_javascript %}
{% bootstrap_messages %}
<!DOCTYPE html>
<html lang="en">
  <head>
    <meta charset="UTF-8" />
    <title>IA Import.html</title>
  </head>

  <body>
    <h1>Arquivo Importado!</h1>
    <p>bdpratico\exemplo02\templates\ia_import_list.html</p>
    <div class="container">
      <div class="row" style="line-height: 1;">
        <div class="col-md-12 col-sm-12 col-xs-12">
          <table class="table table-striped table-hover">
            <th>Grupo</th>
            <th>mdw</th>
            <th>latw</th>
            <th>tmcw</th>
            <th>racw</th>
```



## “Consumindo” Modelos de IA



### ● Criando os templates necessárias na App exemplo02

```
<th>araw</th>
<th>mcw</th>
<th>psdsw</th>
<th>6sw</th>
<th>mdr</th>
<th>...</th>
<th>mcb</th>
<th>psdsb</th>
<th>6sb</th>
{% for regs in dados %}
  <tr>
    <td>{{ regs.grupo }}</td>
    <td>{{ regs.mdw }}</td>
    <td>{{ regs.latw }}</td>
    <td>{{ regs.tmcw }}</td>
    <td>{{ regs.racw }}</td>
    <td>{{ regs.araw }}</td>
    <td>{{ regs.mcw }}</td>
    <td>{{ regs.psdsw }}</td>
    <td>{{ regs.s6w }}</td>
    <td>{{ regs.mdr }}</td>
    <td>...</td>
    <td>{{ regs.mcb }}</td>
    <td>{{ regs.psdsb }}</td>
```



## “Consumindo” Modelos de IA



- Criando os templates necessárias na App exemplo02


```
        <td>{{ regs.s6b }}</td>
    </tr>
    {% endfor %}
</table>
</div>
</div>
</div>
</body>
</html>
```





## “Consumindo” Modelos de IA

- Se os ajustes foram realizados corretamente, após a execução você verá as seguintes telas (exemplo02)




### Upload / Import Arquivo!

bdpratico\exemplo02\templates\ia\_import.html

Choose File No file chosen

Upload



### Arquivo Importado!

bdpratico\exemplo02\templates\ia\_import\_list.html

Grupo	mdw	latw	tmcw	racw	araw	mcw	psdsw	6sw	mdr	...	mcb	psdsb	6sb
Controle	100,67	0,7	3,6	51,66	49,0	52,0	3,27	73,73	94,0	...	54,0	5,97	70,53
Controle	120,0	2,63	3,07	58,33	50,0	70,0	2,77	87,73	112,67	...	66,0	4,9	86,13
Controle	149,33	3,3	4,2	58,93	61,0	88,0	3,37	129,87	142,67	...	76,0	3,93	130,93
Controle	147,33	3,23	4,07	62,44	55,0	92,0	4,9	131,87	136,67	...	88,0	3,43	129,2
Controle	168,0	2,87	3,83	52,38	80,0	88,0	5,3	139,33	162,0	...	86,0	3,07	150,27
Controle	214,0	3,13	6,17	41,12	126,0	88,0	3,33	170,93	218,0	...	124,0	3,43	181,6
Controle	130,0	3,17	4,1	60,0	52,0	78,0	5,1	113,73	132,0	...	78,0	3,3	121,07
Controle	114,0	3,07	4,37	56,14	50,0	64,0	3,17	84,27	111,33	...	66,0	3,47	97,73
Controle	130,0	3,17	3,73	63,08	48,0	82,0	4,7	117,33	126,67	...	84,0	2,87	120,4
Controle	116,0	2,83	3,33	65,52	40,0	76,0	3,0	107,2	110,67	...	74,0	1,57	106,53



## “Consumindo” Modelos de IA

- Agora vamos transferir os dados para o Pandas e construir o classificador knn
- O primeiro passo é instalar o Pandas e o SkLearn

```
pip install pandas  
  
e  
  
pip install scikit-learn
```





## “Consumindo” Modelos de IA

- Na APP Exemplo02, vamos criar a nova rota para o treino do KNN

```
from django.contrib import admin
from django.urls import path
from . import views

urlpatterns = [
    path('', views.index, name='index'),
    path('ia_import', views.ia_import, name='ia_import'),
    path('ia_import_save', views.ia_import_save, name='ia_import_save'),
    path('ia_import_list', views.ia_import_list, name='ia_import_list'),
    path('ia_knn_treino', views.ia_knn_treino, name='ia_knn_treino'),
]
```







## “Consumindo” Modelos de IA



### 🔴 Construindo a função que “treina” o KNN na App exemplo02

```
data['dataset'] = X_train.shape
data['treino'] = X_train.shape[0]
data['teste'] = X_test.shape[0]
data['validacao'] = X_val.shape[0]
print(f'Tamanho do conjunto de treino: {X_train.shape}')
print(f'Tamanho do conjunto de teste: {X_test.shape}')
print(f'Tamanho do conjunto de validação: {X_val.shape}')

from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import accuracy_score

# Instanciando o KNN
knn = KNeighborsClassifier()

# Definindo o grid de parâmetros para o KNN
param_grid = {
    'n_neighbors': [3, 5, 7, 9], # Exemplos de valores possíveis
    'weights': ['uniform', 'distance'], # Tipos de pesos
    'metric': ['euclidean', 'manhattan'] # Tipos de distância
}

# Usando o GridSearchCV para encontrar os melhores parâmetros
grid_search = GridSearchCV(estimator=knn, param_grid=param_grid, cv=5, verbose=2,
n_jobs=-1)
```



## “Consumindo” Modelos de IA

django

Pandas



### 🟡 Construindo a função que “treina” o KNN na App exemplo02

```
# Treinando o modelo com os dados de treino
grid_search.fit(X_train, y_train)

# Melhor conjunto de parâmetros
data['best'] = grid_search.best_params_
print("Melhores parâmetros encontrados:", grid_search.best_params_)

# Obter o melhor modelo
best_knn = grid_search.best_estimator_

# Previsões no conjunto de validação
y_val_pred = best_knn.predict(X_val)

# Avaliação do modelo (Accuracy)
val_accuracy = accuracy_score(y_val, y_val_pred)
print(f'Acurácia no conjunto de validação: {val_accuracy * 100:.2f}%')
data['acc_validacao'] = round(val_accuracy * 100, 2)

# Previsões no conjunto de teste
y_test_pred = best_knn.predict(X_test)
# Avaliação do modelo no conjunto de teste
test_accuracy = accuracy_score(y_test, y_test_pred)
data['acc_teste'] = round(test_accuracy * 100, 2)
print(f'Acurácia no conjunto de teste: {test_accuracy * 100:.2f}%')
```



## “Consumindo” Modelos de IA

### 🕒 Construindo a função que “treina” o KNN na App exemplo02

```
import joblib
# Salvar o modelo treinado com o joblib
model_filename = 'knn_model.pkl' # Caminho do arquivo onde o modelo será salvo
joblib.dump(best_knn, model_filename)
print(f'Modelo salvo em: {model_filename}')
data['file'] = model_filename

return render(request, 'ia_knn_treino.html', data)
```





## “Consumindo” Modelos de IA



### ● Exibindo os resultados em um template HTML na APP exemplo02

```
{% load static %}
{% load bootstrap5 %}
{% bootstrap_css %}
{% bootstrap_javascript %}
{% bootstrap_messages %}
<!DOCTYPE html>
<html lang="en">
  <head>
    <meta charset="UTF-8" />
    <title>IA Knn.html</title>
  </head>

  <body>
    <h1>Dados do Treinamento - KNN</h1>
    <p>bdpratico\exemplo02\templates\ia_knn_treino.html</p>
    <div class="container">
      <div class="row" style="line-height: 1;">
        <div class="col-md-12 col-sm-12 col-xs-12">
          <table class="table table-striped table-hover">
            <th>Descrição</th>
            <th>Valor</th>
            <tr>
              <td>Dataset:</td>
              <td>{{ dataset }}</td>
```





## “Consumindo” Modelos de IA

- Exibindo os resultados em um template HTML na APP exemplo02



```
</tr>
<tr>
  <td>Treino:</td>
  <td>{{ treino }}</td>
</tr>
<tr>
  <td>Teste:</td>
  <td>{{ teste }}</td>
</tr>
<tr>
  <td>Validação:</td>
  <td>{{ validacao }}</td>
</tr>
<tr>
  <td>Acurácia da Validação:</td>
  <td>{{ acc_validacao }}</td>
</tr>
<tr>
  <td>Acurácia do Teste:</td>
  <td>{{ acc_teste }}</td>
</tr>
```



## “Consumindo” Modelos de IA

- Exibindo os resultados em um template HTML na APP exemplo02

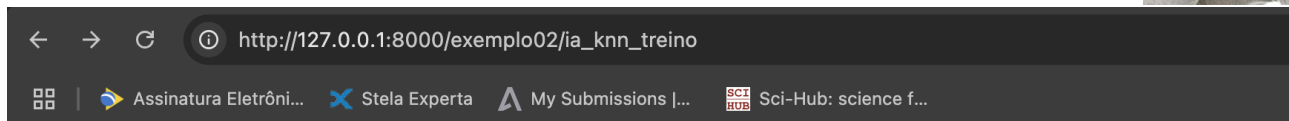


```
<tr>
  <td>Modelo Salvo em:</td>
  <td>{{ file }}</td>
</tr>
</table>
</div>
</div>
</div>
</body>
</html>
```



## “Consumindo” Modelos de IA

- Se os ajustes foram realizados corretamente, após a execução você verá a seguinte tela:



### Dados do Treinamento - KNN

bdpratico\exemplo02\templates\ia\_knn\_treino.html

Descrição	Valor
Dataset:	(29, 32)
Treino:	29
Teste:	7
Validação:	6
Acurácia da Validação:	83,33
Acurácia do Teste:	57,14
Modelo Salvo em:	knn_model.pkl



## “Consumindo” Modelos de IA

### ☉ Exibindo a Matriz de confusão de um modelo treinado (App exemplo02):

```
from django.contrib import admin
from django.urls import path
from . import views

urlpatterns = [
    path('', views.index, name='index'),
    path('ia_import', views.ia_import, name='ia_import'),
    path('ia_import_save', views.ia_import_save, name='ia_import_save'),
    path('ia_import_list', views.ia_import_list, name='ia_import_list'),
    path('ia_knn_treino', views.ia_knn_treino, name='ia_knn_treino'),
    path('ia_knn_matriz', views.ia_knn_matriz, name='ia_knn_matriz'),
]
```





## “Consumindo” Modelos de IA



### 🔴 Exibindo a Matriz de confusão de um modelo treinado (App exemplo02):

```
def ia_knn_matriz(request):
    import joblib
    from sklearn.metrics import confusion_matrix
    import numpy as np
    import pandas as pd
    from .models import dados
    dados_queryset = dados.objects.all()
    df = pd.DataFrame(list(dados_queryset.values()))
    from sklearn.model_selection import train_test_split
    X = df.drop(columns=['grupo', 'id'])
    y = df['grupo']
    model_filename = 'knn_model.pkl'
    best_knn = joblib.load(model_filename)
    y_pred = best_knn.predict(X)
    cm = confusion_matrix(y, y_pred)
    data = {
        'matrix': cm.tolist(),
        'labels': np.unique(y).tolist()
    }
    for i in data['matrix']:
        print(i)
    return render(request, 'ia_knn_matriz.html', data)
```



## “Consumindo” Modelos de IA



### Exibindo os resultados em um template HTML – App exemplo02

```
{% load static %}
{% load bootstrap5 %}
{% bootstrap_css %}
{% bootstrap_javascript %}
{% bootstrap_messages %}

<!DOCTYPE html>
<html lang="pt-br">
  <head>
    <meta charset="UTF-8" />
    <meta name="viewport" content="width=device-width, initial-scale=1.0" />
    <title>Matriz de Confusão</title>
  </head>
  <body>
    <div class="container mt-5">
      <h1 class="text-center">Matriz de Confusão</h1>
      <p class="text-center">Exibindo a matriz de confusão gerada pelo modelo</p>

      <table class="table table-bordered table-striped table-hover table-sm">
        <thead class="table-dark">
          <tr>
            <th></th>
```



## “Consumindo” Modelos de IA




### Exibindo os resultados em um template HTML – App exemplo02

```
{% for coluna in labels %}
  <th class="text-center">{{ coluna }}</th>
{% endfor %}
</tr>
</thead>
<tbody>
  {% for row in matrix %}
    <tr>
      {% if forloop.counter == 1 %}
        <th class="text-end">{{ labels.0 }}</th>
      {% endif %}
      {% if forloop.counter == 2 %}
        <th class="text-end">{{ labels.1 }}</th>
      {% endif %}
      {% for value in row %}
        <td class="text-center">{{ value }}</td>
      {% endfor %}
    </tr>
  {% endfor %}
</tbody>
</table>
</div>
</body>
</html>
```



## “Consumindo” Modelos de IA

- Se os ajustes foram realizados corretamente, após a execução você verá a seguinte tela:



## Matriz de Confusão

Exibindo a matriz de confusão gerada pelo modelo

	Controle	Experimental
Controle	18	3
Experimental	7	14

		Classe Real	
		+	-
Classe Predita	+	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	-	Falso Negativo (FN)	Verdadeiro Negativo (VN)





## “Consumindo” Modelos de IA

### ☉ Exibindo a Curva ROC de um modelo treinado (App exemplo02):

```
from django.contrib import admin
from django.urls import path
from . import views

urlpatterns = [
    path('', views.index, name='index'),
    path('ia_import', views.ia_import, name='ia_import'),
    path('ia_import_save', views.ia_import_save, name='ia_import_save'),
    path('ia_import_list', views.ia_import_list, name='ia_import_list'),
    path('ia_knn_treino', views.ia_knn_treino, name='ia_knn_treino'),
    path('ia_knn_matriz', views.ia_knn_matriz, name='ia_knn_matriz'),
    path('ia_knn_roc', views.ia_knn_roc, name='ia_knn_roc'),
]
```





## “Consumindo” Modelos de IA

### ● Exibindo a Curva ROC de um modelo treinado (App exemplo02):

```
def ia_knn_roc(request):
    import joblib
    import pandas as pd
    from sklearn.metrics import roc_curve, auc
    import plotly.graph_objects as go
    import numpy as np
    from .models import dados
    from django.shortcuts import render

    dados_queryset = dados.objects.all()
    df = pd.DataFrame(list(dados_queryset.values()))
    X = df.drop(columns=['grupo', 'id'])
    y = df['grupo'].map({'Controle': -1, 'Experimental': 1})
    model_filename = 'knn_model.pkl'
    best_knn = joblib.load(model_filename)
    y_pred_prob = best_knn.predict_proba(X)[:, 1]
    fpr, tpr, thresholds = roc_curve(y, y_pred_prob)
    roc_auc = auc(fpr, tpr)
```





## “Consumindo” Modelos de IA

### ● Exibindo a Curva ROC de um modelo treinado (App exemplo02):

```
fig = go.Figure()
fig.add_trace(go.Scatter(x=fpr, y=tpr, mode='lines', name=f'ROC Curve (AUC =
{roc_auc:.2f})', line=dict(color='blue'))))
fig.add_trace(go.Scatter(x=[0, 1], y=[0, 1], mode='lines', name='Random Classifier',
line=dict(dash='dash', color='gray'))))
fig.update_layout(
    title='Curva ROC',
    xaxis_title='Taxa de Falsos Positivos (FPR)',
    yaxis_title='Taxa de Verdadeiros Positivos (TPR)',
    showlegend=True
)
graph = fig.to_html(full_html=False)
return render(request, 'ia_knn_roc.html', {'graph': graph})
```





## “Consumindo” Modelos de IA



### ● Exibindo os resultados em um template HTML – App exemplo02

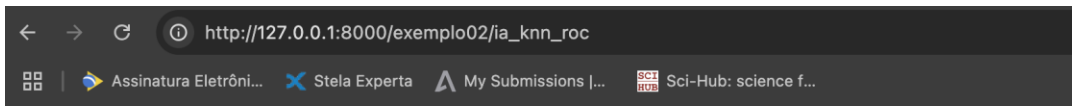
```
{% load static %}
{% load bootstrap5 %}
{% bootstrap_css %}
{% bootstrap_javascript %}
{% bootstrap_messages %}

<!DOCTYPE html>
<html lang="pt-br">
  <head>
    <meta charset="UTF-8" />
    <meta name="viewport" content="width=device-width, initial-scale=1.0" />
    <title>Curva ROC</title>
  </head>
  <body>
    <div class="container mt-5">
      <h1 class="text-center">Curva ROC do Modelo KNN</h1>
      <div class="text-center">
        {{ graph|safe }}
      </div>
    </div>
  </body>
</html>
```

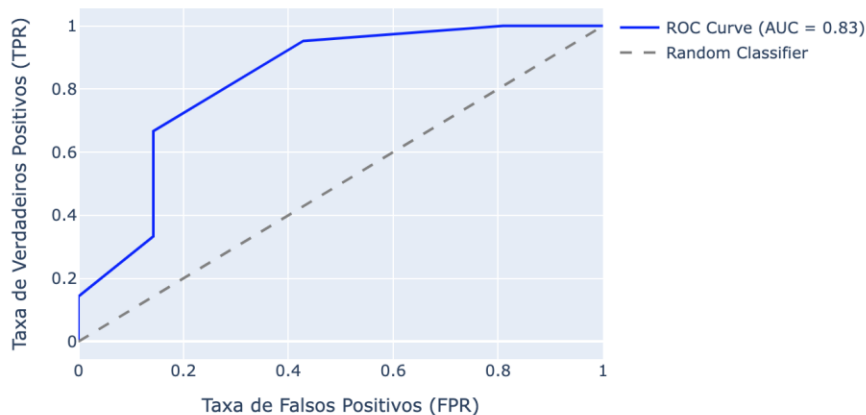


## “Consumindo” Modelos de IA

- Se os ajustes foram realizados corretamente, após a execução você verá a seguinte tela:



Curva ROC





## “Consumindo” Modelos de IA

### ☉ Exibindo a Curva Recall de um modelo treinado (App exemplo02):

```
from django.contrib import admin
from django.urls import path
from . import views

urlpatterns = [
    path('', views.index, name='index'),
    path('ia_import', views.ia_import, name='ia_import'),
    path('ia_import_save', views.ia_import_save, name='ia_import_save'),
    path('ia_import_list', views.ia_import_list, name='ia_import_list'),
    path('ia_knn_treino', views.ia_knn_treino, name='ia_knn_treino'),
    path('ia_knn_matriz', views.ia_knn_matriz, name='ia_knn_matriz'),
    path('ia_knn_roc', views.ia_knn_roc, name='ia_knn_roc'),
    path('ia_knn_recall', views.ia_knn_recall, name='ia_knn_recall'),
]
```





## “Consumindo” Modelos de IA

### ● Exibindo a Curva Recall de um modelo treinado (App exemplo02):

```
def ia_knn_recall(request):
    import joblib
    import pandas as pd
    from sklearn.metrics import precision_recall_curve, auc
    import plotly.graph_objects as go
    import numpy as np
    from .models import dados
    from django.shortcuts import render

    dados_queryset = dados.objects.all()
    df = pd.DataFrame(list(dados_queryset.values()))
    X = df.drop(columns=['grupo', 'id'])
    y = df['grupo'].map({'Controle': -1, 'Experimental': 1})
    model_filename = 'knn_model.pkl'
    best_knn = joblib.load(model_filename)
    y_pred_prob = best_knn.predict_proba(X)[:, 1]
    precision, recall, thresholds = precision_recall_curve(y, y_pred_prob)
    pr_auc = auc(recall, precision)
```

django

Pandas





## “Consumindo” Modelos de IA

### ☉ Exibindo a Curva Recall de um modelo treinado (App exemplo02):

```
fig = go.Figure()
fig.add_trace(go.Scatter(x=recall, y=precision, mode='lines', name=f'Precision-Recall
Curve (AUC = {pr_auc:.2f})', line=dict(color='blue'))))
fig.add_trace(go.Scatter(x=[0, 1], y=[0, 0], mode='lines', name='Random Classifier',
line=dict(dash='dash', color='gray'))))
fig.update_layout(
    title='Curva Precision-Recall',
    xaxis_title='Recall',
    yaxis_title='Precision',
    showlegend=True
)
graph = fig.to_html(full_html=False)
return render(request, 'ia_knn_recall.html', {'graph': graph})
```







## “Consumindo” Modelos de IA



### ● Exibindo os resultados em um template HTML – App exemplo02

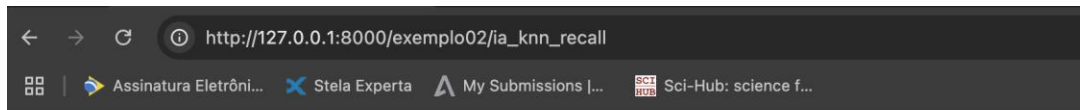
```
{% load static %}
{% load bootstrap5 %}
{% bootstrap_css %}
{% bootstrap_javascript %}
{% bootstrap_messages %}

<!DOCTYPE html>
<html lang="pt-br">
  <head>
    <meta charset="UTF-8" />
    <meta name="viewport" content="width=device-width, initial-scale=1.0" />
    <title>Curva Precision-Recall</title>
  </head>
  <body>
    <div class="container mt-5">
      <h1 class="text-center">Curva Precision-Recall do Modelo KNN</h1>
      <div class="text-center">
        {{ graph|safe }}
      </div>
    </div>
  </body>
</html>
```

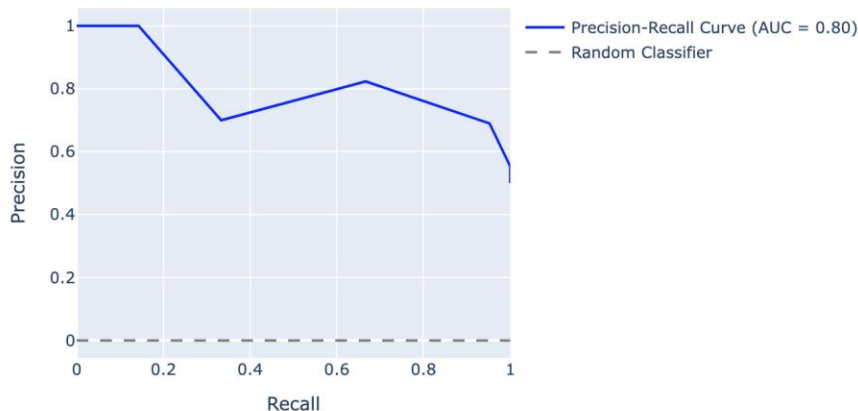


## “Consumindo” Modelos de IA

- Se os ajustes foram realizados corretamente, após a execução você verá a seguinte tela:



Curva Precision-Recall



**Universidade Federal de Goiás**  
**Instituto de Informática**  
**Prof. Ronaldo Martins da Costa**

